

# 基于稀疏表示的多标记学习算法\*

宋相法 焦李成

(西安电子科技大学 智能感知与图像理解教育部重点实验室 西安 710071)

**摘 要** 为解决多标记数据的分类问题,提出基于稀疏表示的多标记学习算法. 首先将待分类样本表示为训练样本集上的稀疏线性组合,基于  $l^1$ -最小化方法求得最稀疏的系数解. 然后利用稀疏系数的判别信息提出一个计算待分类样本对各标记的隶属度的方法. 最后根据隶属度对标记进行排序,进而完成分类. 在 Yeast 基因功能分析、自然场景分类和 web 页面分类上的实验表明,该算法能够有效解决多标记数据的分类问题,与其它方法相比取得更好的结果.

**关键词** 机器学习, 多标记学习, 稀疏表示, 压缩感知,  $l^1$ -最小化  
中图分类号 TP 181

## A Multi-Label Learning Algorithm Based on Sparse Representation

SONG Xiang-Fa, JIAO Li-Cheng

(Key Laboratory of Intelligent Perception and Image Understanding of Ministry of Education,  
Xidian University, Xi'an 710071)

### ABSTRACT

To solve the problem of multi-label data classification, a multi-label learning algorithm based on sparse representation is proposed. The testing samples are treated as a sparse linear combination of training samples, and the sparsest coefficients are obtained by using  $l^1$ -minimization. Then, the discriminating information of sparse coefficients is utilized to calculate membership function of the testing sample. Finally, the labels are ranked according to the membership function and the classification is completed. Extensive experiments are conducted on gene functional analysis, natural scene classification and web page categorization, and experimental results demonstrate the effectiveness of the proposed method. The results also show that the proposed method based on sparse representation achieves better results than other algorithms.

**Key Words** Machine Learning, Multi-Label Learning, Sparse Representation, Compressed Sensing,  $l^1$ -Minimization

\* 国家自然科学基金项目 (No. 60971112, 60971128, 60970067)、中央高校基本科研业务费专项资金项目 (No. JY10000902001, JY10000902041, JY10000902043) 资助

收稿日期: 2010-10-08; 修回日期: 2011-01-28

作者简介 宋相法, 男, 1975 年生, 博士研究生, 主要研究方向为机器学习和模式识别等. E-mail: xiangfasong@163.com. 焦李成, 男, 1959 年生, 教授, 博士生导师, 主要研究方向为智能计算、机器学习和智能信息处理等.

## 1 引言

在传统的机器学习框架下,每个样本只属于一个类,即一个样本仅有一个标记.与此相反,在多标记学习(Multi-Label Learning)框架下,一个样本可同时属于多个类,即一个样本具有多个标记.多标记学习任务在现实世界中普遍存在.例如,在文本分类中,每个文本往往同时属于多个题材类别<sup>[1]</sup>;在基因数据中,每个基因可能对应多个不同的功能<sup>[2]</sup>;在语义场景分类中,按照图像中所包含内容的不同,同一幅场景图像可能属于不同类别<sup>[3]</sup>.因此,为了解决上述问题,研究人员提出多标记学习框架.

多标记数据属于一个或多个类别,因此其分类问题比单标记分类更为复杂,研究人员已提出一些多标记学习算法.文献[1]在对 AdaBoost 扩展的基础上,提出基于集成学习的多标记分类算法 BOOST-EXTER,并将其用于多标记文档分类;文献[2]提出基于核的多标记分类算法 Rank-SVM,并利用该算法对基因数据进行分类,取得好的分类效果;文献[3]把多标记分类技术应用于自然场景分类,把多标记分类问题分解为多个相互独立的两类问题,提出一些把两类分类器的输出组合起来预测标记的规则;文献[4]提出基于二叉决策树的多标记学习算法——ADABOOST.MH;文献[5]将传统的  $K$  近邻算法和贝叶斯理论相结合,提出多标记学习算法 ML-KNN.

本文以最近发展起来的稀疏表示(Sparse Representation)<sup>[6]</sup>和压缩感知(Compressed Sensing)理论<sup>[7-9]</sup>为基础,提出基于稀疏表示的多标记学习算法.该算法利用训练样本集在  $l^1$  约束下稀疏地表示待分类样本,与大于零的系数相对应的训练样本被看做与待分类样本标记相关,所得稀疏解含有的判别信息可用于分类和识别,基于这些判别信息提出一种为待分类样本预测标记集的方法.在 Yeast 基因功能分析、自然场景分类和自动 web 页面分类上的实验表明本文算法能够有效解决多标记数据分类问题,与现有方法相比有更好的性能.

## 2 多标记学习

令  $X = \mathbf{R}^d$  表示输入空间,  $\Omega = \{1, 2, \dots, L\}$  为有限标记集合.给定多标记训练样本集合

$$D = \{(x_1, Y_1), (x_2, Y_2), \dots, (x_n, Y_n)\},$$

其中  $x_i \in X$  为一个样本,  $Y_i \subseteq \Omega$  为  $x_i$  的一个合适标

记集.多标记学习系统的目的是学得一个多标记分类器  $h: X \rightarrow 2^\Omega$ , 该分类器为样本预测一个标记集.

通常情况下,定义一个实值函数  $f: X \times \Omega \rightarrow \mathbf{R}$  来计算样本  $x_i$  属于类别标记  $l$  的隶属程度.如果样本  $x_i$  的标记集为  $Y_i$ , 当  $l_1 \in Y_i, l_2 \notin Y_i$  时,  $f(x_i, l_1) > f(x_i, l_2)$ . 定义排序函数  $rank_f(\cdot)$ , 如果  $f(x_i, l_1) > f(x_i, l_2)$ , 则  $rank_f(x_i, l_1) < rank_f(x_i, l_2)$ . 排序函数的值越小, 该标记的优先级越高, 样本  $x_i$  属于该标记的隶属程度越大.此外, 根据  $f(\cdot, \cdot)$  定义预测标记集  $h(x_i) = \{l | f(x_i, l) > t(x_i), l \in \Omega\}$ , 其中  $t(x_i)$  为阈值函数.

## 3 基于稀疏表示的多标记学习算法

利用训练样本集  $D$  构造一个超完备基字典

$$A = [x_1, x_2, \dots, x_n] \in \mathbf{R}^{d \times n}, d < n,$$

这里“超完备基字典”的含义是指字典中样本的个数大于样本的维数.根据训练样本集  $D$  的标记集信息构造一个  $L \times n$  的矩阵  $B$ , 其中,  $n$  表示训练集合  $D$  中的样本数目,  $L$  表示不同标记的个数.矩阵  $B$  的第  $i$  列  $b_i$  是样本  $x_i$  的标记向量.如果  $x_i$  属于标记集中的某个标记  $l$ , 则  $b_{li} = 1$ , 否则为 0.

### 3.1 基于 $l^1$ -最小化方法的稀疏求解

数据的稀疏表示已被广泛应用于信号和图像处理领域, 如信号和图像的分离与去噪<sup>[10-11]</sup>.最近的研究表明, 在  $l^1$  约束下, 待分类样本在训练样本集上的稀疏表示所包含的判别信息可用于分类和识别.由于稀疏表示考虑到训练样本的全体上下文信息和数据噪声的存在, 因此该方法是精确的.稀疏表示已在计算机视觉、机器学习和模式识别等领域取得成功应用<sup>[6, 12-14]</sup>.本文利用稀疏表示解决多标记学习问题, 并基于稀疏表示的判别信息提出一种为待分类样本预测标记集的方法.

给定待分类样本为  $x \in X$ , 则可将  $x$  表示为训练集中所有样本的线性组合:

$$x = A\alpha, \quad (1)$$

其中,  $\alpha \in \mathbf{R}^n$  为待求解的系数.一般情况下  $d < n$ , 方程(1)是一个线性的欠定系统.在线性的欠定系统中求解稀疏解是 NP 难问题.压缩感知理论<sup>[7-9]</sup>表明, 如果解  $\alpha$  是充分稀疏的, 可用下面的  $l^1$ -最小化方法求解:

$$\min_{\alpha} \|\alpha\|_1, \text{ s.t. } x = A\alpha.$$

因为实际数据中一般都含有噪声, 精确的  $x = A\alpha$  不再满足.为解决这个问题, 文献[6]对上式进行改

进,改进后的公式如下:

$$\mathbf{x} = \mathbf{A}\boldsymbol{\alpha} + \mathbf{z},$$

其中,  $\mathbf{z}$  是一个噪声项且  $\|\mathbf{z}\|_2 < \varepsilon$ . 因此,数据的稀疏表示问题可通过求解下面稳定的  $l^1$ -最小化问题来求得,即

$$\min_{\boldsymbol{\alpha}} \|\boldsymbol{\alpha}\|_1, \text{ s. t. } \|\mathbf{x} - \mathbf{A}\boldsymbol{\alpha}\|_2 \leq \varepsilon.$$

该约束优化问题可转化为带一个附加正则项系数的无约束问题:

$$\min_{\boldsymbol{\alpha}} \frac{1}{2} \|\mathbf{x} - \mathbf{A}\boldsymbol{\alpha}\|_2^2 + \lambda \|\boldsymbol{\alpha}\|_1 \quad (2)$$

进行求解,其中正参数  $\lambda$  是一个正则化因子,用来平衡重构错误和  $\boldsymbol{\alpha}$  的稀疏度. 求解问题(2)的算法复杂度为多项式时间,易于实现,本文利用文献[15]提出的算法求解问题(2).

文献[15]算法的基本思想是将梯度投影算法应用于问题(2)的二次规划形式. 该算法每一步的搜索路径是通过负梯度方向向可行域投影得到的. 该算法在终止准则以及最终除偏相位 (Final Debiasing Phase) 方面通过对问题(2)的解的支撑集进行最小二乘拟合得到,从而加强该算法,而这些加强使得该算法能够有效求解问题(2). 更详细的分析请参考文献[15].

### 3.2 基于稀疏系数的标记预测

给定一个新的待分类样本  $\mathbf{x} \in \mathbf{X}$ , 首先通过式(2)计算它的稀疏系数  $\boldsymbol{\alpha}$ . 系数  $\alpha_i$  的值表示训练样本  $\mathbf{x}_i$  重构待分类样本  $\mathbf{x}$  时的贡献<sup>[12]</sup>, 因此具有正系数的训练样本和待分类样本正相关, 正系数值可作为权值. 在多标记学习系统中, 通常定义一个函数  $f$  来表示样本  $\mathbf{x}$  属于类别  $l$  的隶属程度<sup>[16]</sup>, 因此根据正系数值和训练样本的标记集信息矩阵  $\mathbf{B}$ , 本文提出一个函数  $f(\mathbf{x}, l)$  来表示待分类样本属于每个标记的隶属程度. 函数  $f$  定义如下:

$$f(\mathbf{x}, l) = \frac{\sum_{i=1}^n b_{li} \hat{\alpha}_i}{\sum_{i=1}^n \hat{\alpha}_i}, \quad (3)$$

其中

$$\hat{\alpha}_i = \begin{cases} \alpha_i, & \alpha_i > 0 \\ 0, & \alpha_i \leq 0 \end{cases}$$

$i = 1, 2, \dots, n$ .

利用式(3)计算待分类样本属于每个标记的隶属程度, 根据  $f(\mathbf{x}, l)$  的大小对标记排序, 从而为待分类样本  $\mathbf{x}$  预测标记集  $h(\mathbf{x})$ .

本文算法的步骤如下.

step 1 输入超完备基  $\mathbf{A} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n]$ , 标

记集信息矩阵  $\mathbf{B}$ , 待分类样本  $\mathbf{x} \in \mathbf{X}$ .

step 2 利用  $l^1$ -范数对  $\mathbf{A}$  中的每一列归一化.

step 3 利用式(2)求解稀疏系数  $\boldsymbol{\alpha}$ .

step 4 利用式(3)计算待分类样本  $\mathbf{x}$  属于标记  $l \in \{1, 2, \dots, L\}$  的隶属度值.

step 5 输出待分类样本标记集

$$h(\mathbf{x}) = \{l | f(\mathbf{x}, l) > 0.5, l \in \Omega\},$$

如果上式为空, 则

$$h(\mathbf{x}) = \{l | \max_i (f(\mathbf{x}, l)), l \in \Omega\}.$$

## 4 实验与分析

### 4.1 算法性能评价指标

为了对本文算法的性能进行评价, 下面给出用于衡量多标记学习系统性能的指标<sup>[1]</sup>, 设待分类样本集  $S = \{(\mathbf{x}_1, Y_1), (\mathbf{x}_2, Y_2), \dots, (\mathbf{x}_p, Y_p)\}$ .

1) 汉明损失 (Hamming Loss):

$$hloss_S(h) = \frac{1}{p} \sum_{i=1}^p \frac{1}{L} |h(\mathbf{x}_i) \Delta Y_i|,$$

其中  $\Delta$  操作求两个集合中不相同的元素个数. 该指标评价待分类样本集合中各样本的预测标记集与实际标记集之间的匹配错误率.

2) 1- 错误率 (One-Error):

$$one-error_S(f) = \frac{1}{p} \sum_{i=1}^p \{ [\arg \max_{l \in \Omega} f(\mathbf{x}_i, l)] \notin Y_i \},$$

其中, 对于任意  $\pi$ , 当  $\pi$  为真时,  $[\pi] = 1$ , 否则  $[\pi] = 0$ . 该指标评价实际标记集中的第一个标记没有出现在预测标记集中的概率.

3) 覆盖率 (Coverage):

$$coverage_S(f) = \frac{1}{p} \sum_{i=1}^p \max_{l \in Y_i} rank_f(\mathbf{x}_i, l) - 1,$$

该指标评价平均需要将标记序列下降多少可覆盖样本对应的所有合适标记.

4) 排序损失 (Ranking Loss):

$$rloss_S(f) = \frac{1}{p} \sum_{i=1}^p \left[ \frac{1}{|Y_i| |\bar{Y}_i|} \cdot \right.$$

$$\left. | \{ (l_1, l_2) | f(\mathbf{x}_i, l_1) \leq f(\mathbf{x}_i, l_2), (l_1, l_2) \in Y_i \times \bar{Y}_i \} | \right],$$

其中,  $\bar{Y}_i$  表示  $Y_i$  的补. 该指标评价待分类集合中各样本的预测标记集和实际标记集中排序不相同的程度.

5) 平均精度 (Average Precision):

$$avgprec_S(f) = \frac{1}{p} \sum_{i=1}^p \frac{1}{|Y_i|} \cdot$$

$$\sum_{l' \in Y_i} \frac{|\{l' | rank_f(\mathbf{x}_i, l') \leq rank_f(\mathbf{x}_i, l), l' \in Y_i\}|}{rank_f(\mathbf{x}_i, l)},$$

该指标评价预测标记的平均精度.

在上述 5 个评价指标中,前 4 个指标的值越小,则学习系统的性能越好;Average Precision 的值越大,则学习系统的性能越好。

4.2 实验数据集

在实验中,为了包括多种数据特征,全面反映本文算法的性能,选择 3 大类数据集,这些数据集是多标记学习领域的常用数据集。

1)Yeast 基因功能分析.第 1 个数据集是 Yeast 酵母菌基因数据集,其任务是通过分析已知功能类别的 Yeast 酵母菌基因,为待分类 Yeast 酵母菌基因预测功能类别.该数据集中每个基因具有多个功能类别,整个功能类别分为 4 层.原始数据集非常复杂,为了简化问题,本文采用的数据集是由文献[2]处理后的数据集.该数据集包含 2 417 个基因,每个基因的特征维数是 103.基因总类别数为 14 种,每个基因的平均标记个数为  $4.24 \pm 1.57$ .

2)自然场景分类.第 2 个数据集来源于 corel image collection (<http://cse.seu.edu.cn/people/zhangml/>),其任务是通过分析已知标记集的图像为待分类图像预测标记集.该数据集共包含 2 000 张内容不同的风景图像,内容的总类别:沙漠、山、海洋、日落、树木.每张图像首先通过人工交互判断所包含的景物,然后将标记集赋予该图像.利用文献[3]的方法,每张图像表示为一个 294 维的特征向量,同时属于多个类别的图像个数超过总数据的 22%,每张图像的平均标记个数为  $1.24 \pm 0.44$ .

3)web 页面分类.第 3 个数据集是 web 页面数据集,其任务是通过分析已知标记集的 web 页面对

测试 web 页面进行标记.该数据集是从 [www.yahoo.com](http://www.yahoo.com) 收集的 web 页面,共有 11 个子数据集.每个子数据集包含训练集 2 000 个文本和测试集 3 000 个文本.利用文献[5]的方法,每个 web 页面表示为 1 个特征向量.在这 11 个子数据集中,多标记的文本占 20%~45%.每个子数据集包含的类别数为 21~40,每个文本的维数为 438~1 047.

4.3 实验结果

为了对本文算法的性能进行详细分析,与另外 4 种多标记学习算法的结果和性能指标进行比较,包括基于集成学习的多标记学习算法 BOOSTEXTER<sup>[1]</sup>,基于核的多标记学习算法 RANK-SVM<sup>[2]</sup>,基于决策树的多标记学习算法 ADABOOST.MH<sup>[4]</sup>,基于 K 近邻算法的多标记学习算法 ML-KNN<sup>[5]</sup>.

同时,为了使得算法具有可比性,实验在基因数据集和自然场景图像数据集上采用十折交叉的验证方法.对于每个评价指标,“↓”表示该性能指标越小越好,“↑”表示该性能指标越大越好,最优结果用粗体表示.实验结果如表 1 和表 2 所示.

表 1 比较各种算法在 Yeast 基因数据集上的实验结果.好的多标记学习算法应该具有较低的汉明损失、1-错误率、覆盖率和排序损失,较高的平均精度.从表 1 中可看出,本文算法在汉明损失、1-错误率、覆盖率和排序损失上低于其它 4 种算法,在平均精度上高于其它 4 种算法,其整体性能是最好的.其中,本文算法在汉明损失上低于 ML-KNN 4 个百分点,在平均精度上超出 ML-KNN 2 个百分点,而 ML-KNN 是当前多标记学习领域效果最好的方法之一.

表 1 5 种多标记算法在基因数据上的实验结果(均值)  
Table 1 Experimental results (mean) of 5 multi-label learning algorithms on gene datasets

| 方法          | 汉明缺失↓        | 错误率↓         | 覆盖率↓         | 排序缺失↓        | 平均精度↑/%     |
|-------------|--------------|--------------|--------------|--------------|-------------|
| 本文算法        | <b>0.185</b> | <b>0.209</b> | <b>6.052</b> | <b>0.156</b> | <b>77.9</b> |
| ML-KNN      | 0.194        | 0.230        | 6.275        | 0.167        | 76.5        |
| BOOSTEXTER  | 0.220        | 0.278        | 6.550        | 0.186        | 73.7        |
| ADABOOST.MH | 0.207        | 0.244        | 6.390        | N/A          | 74.4        |
| RANK-SVM    | 0.207        | 0.243        | 7.090        | 0.195        | 74.9        |

表 2 5 种多标记算法在自然场景图像数据上的实验结果(均值)  
Table 2 Experimental results (mean) of 5 multi-label learning algorithms on natural scene image datasets

| 方法          | 汉明缺失↓        | 错误率↓         | 覆盖率↓         | 排序缺失↓        | 平均精度↑/%     |
|-------------|--------------|--------------|--------------|--------------|-------------|
| 本文算法        | <b>0.146</b> | <b>0.247</b> | <b>0.807</b> | <b>0.135</b> | <b>83.8</b> |
| ML-KNN      | 0.196        | 0.300        | 0.939        | 0.168        | 80.3        |
| BOOSTEXTER  | 0.179        | 0.311        | 0.939        | 0.168        | 79.8        |
| ADABOOST.MH | 0.193        | 0.375        | 1.102        | N/A          | 75.5        |
| RANK-SVM    | 0.253        | 0.491        | 1.382        | 0.278        | 68.2        |

表 3 5 种多标记算法在 web 页面数据上的实验结果(均值)

Table 3 Experimental results (mean) of 5 multi-label learning algorithms on web page datasets

| 方法           | 汉明缺失↓        | 错误率↓         | 覆盖率↓         | 排序缺失↓        | 平均精度↑/%     |
|--------------|--------------|--------------|--------------|--------------|-------------|
| 本文算法         | 0.044        | <b>0.404</b> | <b>3.730</b> | <b>0.088</b> | <b>68.0</b> |
| ML-KNN       | <b>0.043</b> | 0.471        | 4.097        | 0.102        | 62.5        |
| BOOSTEXTER   | 0.046        | 0.446        | 4.213        | 0.103        | 63.8        |
| ADABOOST. MH | <b>0.043</b> | 0.461        | 4.083        | N/A          | 63.2        |
| RANK-SVM     | <b>0.043</b> | 0.440        | 7.508        | 0.193        | 60.5        |

表 2 比较各种算法在自然场景图像数据集上的实验结果. 从表 2 中可看出, 本文算法在汉明损失、1-错误率、覆盖率和排序损失上远低于其它 4 种算法, 在平均精度上远高于其它 4 种算法, 其整体性能远好于其它 4 种算法. 其中, 本文算法在汉明损失上低于 ML-KNN 25 个百分点, 在平均精度上超出 ML-KNN 4 个百分点.

表 3 比较各种算法在 web 页面数据集上的实验结果. 从表 3 中可看出, 本文算法的整体性能也是最好的. 在汉明损失上略微高于 ML-KNN、ADABOOST. MH 和 RANK-SVM, 然而在 1-错误率、覆盖率、排序损失上远低于其它 4 种算法, 在平均精度上远高于其它 4 种算法. 其中, 本文算法在平均精度上超出 ML-KNN 9 个百分点.

根据本文算法在基因数据集、自然场景图像数据集和 web 页面数据集上的实验结果可得如下结论, 与经典的 ML-KNN 算法、BOOSTEXTER 算法、ADABOOST. MH 算法和 RANK-SVM 算法相比, 本文算法提高分类精确度, 且其它各项性能指标也都达到较高水平, 能够有效解决多标记数据分类问题. 这是因为稀疏表示具有很强的鉴别力, 它具有选择最能紧致表示测试样本的训练样本的能力, 并且它充分利用训练样本集的整体上下文信息, 所以算法可提高分类精度和其它性能.

## 5 结束语

多标记学习是机器学习领域一个新的研究方向, 有着很强的应用背景. 研究行之有效的多标记学习算法, 对解决多标记数据分类问题有着重要的现实意义. 本文基于稀疏表示和压缩感知理论, 提出一种基于稀疏表示的多标记学习算法. 算法首先利用训练样本构建超完备基字典, 并把待分类样本表示为其上的线性组合, 基于  $l^1$  最小化方法求得稀疏解, 然后利用稀疏表示的判别信息提出一种为待分类样本预测标记的方法. 在基因数据集、自然场景图像数据集和

web 页面数据集上的实验表明, 根据多标记算法的评价指标, 本文算法的分类精度高于其他典型的算法, 且其它指标也达到较好水平. 下一步研究工作的重点是构建性能更好的稀疏表示模型, 进一步提高算法的分类精度, 降低算法的时间复杂度.

## 参 考 文 献

- [1] Schapire R E, Singer Y. Boostexter: A Boosting-Based System for Text Categorization. *Machine Learning*, 2000, 39(2/3): 135 - 168
- [2] Elisseeff A, Weston J. A Kernel Method for Multi-Labelled Classification // Dietterich T G, Becker S, Ghahramani Z, eds. *Advances in Neural Information Processing Systems*. Cambridge, USA: MIT Press, 2002, XIV: 681 - 687
- [3] Boutell M R, Luo J, Shen X, et al. Learning Multi-Label Scene Classification. *Pattern Recognition*, 2004, 37(9): 1757 - 1771
- [4] de Comité F, Gilleron R, Tommasi M. Learning Multi-Label Alternating Decision Tree from Texts and Data // Proc of the 3rd International Conference on Machine Learning and Data Mining in Pattern Recognition. Leipzig, Germany, 2003: 35 - 49
- [5] Zhang Minling, Zhou Zhihua. ML-KNN: A Lazy Learning Approach to Multi-Label Learning. *Pattern Recognition*, 2007, 40(7): 2038 - 2048
- [6] Wright J, Yang A Y, Ganesh A, et al. Robust Face Recognition via Sparse Representation. *IEEE Trans on Pattern Analysis and Machine Intelligence*, 2009, 31(2): 201 - 227
- [7] Candès E J, Romberg J, Tao T. Robust Uncertainty Principles: Exact Signal Reconstruction from Highly Incomplete Frequency Information. *IEEE Trans on Information Theory*, 2006, 52(2): 489 - 509
- [8] Candès E J, Tao T. Near-Optimal Signal Recovery from Random Projections: Universal Encoding Strategies? *IEEE Trans on Information Theory*, 2006, 52(12): 5406 - 5425
- [9] Donoho D. For Most Large Underdetermined Systems of Linear Equations the Minimal  $l^1$ -norm Solution Is Also the Sparsest Solution. *Communications on Pure and Applied Mathematics*, 2006, 59(6): 797 - 829
- [10] Zhao Ruizhen, Liu Xiaoyu, Li C C, et al. Sparse Representation-Based Wavelet De-Noising. *Science China: Information Sciences*, 2010, 40(1): 33 - 40 (in Chinese)  
(赵瑞珍, 刘晓宇, Li C C, 等. 基于稀疏表示的小波去噪. *中国科学: 信息科学*, 2010, 40(1): 33 - 40)
- [11] Cai Zemin, Lai Jianhuang. An Over-Complete Learned Dictionary-

- Based Image De-Noising Method. *Acta Electronica Sinica*, 2009, 37(2): 347–350 (in Chinese)  
(蔡泽民, 赖剑煌. 一种基于超完备字典学习的图像去噪方法. 电子学报, 2009, 37(2): 347–350)
- [12] Qiao Lishan, Chen Songcan, Tan Xiaoyang. Sparsity Preserving Projection with Applications to Face Recognition. *Pattern Recognition*, 2010, 43(1): 331–341
- [13] Cheng Bin, Yang Jianchao, Yan Shuicheng, *et al.* Learning with  $l^1$ -Graph for Image Analysis. *IEEE Trans on Image Processing*, 2010, 19(4): 858–866
- [14] Han Yahong, Wu Fei, Zhuang Yueting, *et al.* Multi-Label Transfer Learning with Sparse Representation. *IEEE Trans on Circuits and Systems for Video Technology*, 2010, 20(8): 1110–1121
- [15] Figueiredo M, Nowak R, Wright S. Gradient Projection for Sparse Reconstruction: Application to Compressed Sensing and Other Inverse Problems. *IEEE Journal on Selected Topics in Signal Processing*, 2007, 1(4): 586–598
- [16] Li Hong, Xie Zheng, Xiang Yao, *et al.* Multi-Label Learning by LLE Dimension Reduction and Bayesian Classification. *Journal of Systems Engineering and Electronics*, 2009, 31(6): 1467–1472 (in Chinese)  
(李宏, 谢政, 向遥, 等. 一种采用 LLE 降维和贝叶斯分类的多类标学习算法. 系统工程与电子技术, 2009, 31(6): 1467–1472)

## 第四届中国 Agent 理论与应用学术会议 (Agent 2012)

### 征 文 通 知

中国 Agent 理论与应用学术会议由中国计算机学会主办, 中国计算机学会人工智能与模式识别专业委员会协办, 每两年召开一次。第四届中国 Agent 理论和应用学术会议将于 2012 年 8 月 3 日至 5 日在吉林省长春市举行。会议由吉林大学计算机科学与技术学院、软件学院, 中国计算机学会人工智能与模式识别专业委员会, 吉林省计算机学会和吉林大学符号计算与知识工程教育部重点实验室联合承办。本次会议旨在为中国人工智能学术界提供一个交流最新研究成果的舞台, 汇聚从事 Agent 理论、技术及应用, 人工智能理论、技术及应用研究的人员, 广泛开展学术交流, 研讨发展战略, 以期促进 Agent 理论、技术及应用的发展。

会议录用的论文将推荐到《软件学报》、《计算机研究与发展》、《模式识别与人工智能》、《计算机科学与探索》、《计算机科学》、《吉林大学学报(工学版)》、《吉林大学学报(理学版)》和《计算机工程与设计》等国内权威或核心期刊上发表。

#### 一、征文范围(但不限于)

##### Agent 理论与技术

- 智能 Agent 理论
- 软件 Agent 体系结构与模式
- 多 Agent 系统社会组织和联盟模型
- 多 Agent 系统协商、合作和竞争
- 多 Agent 系统拍卖、博弈理论与模型
- 面向 Agent 软件工程和需求工程
- Agent 技术与面向服务计算、语义 Web、网格计算和 P2P 计算
- Agent 技术与云计算
- 自治计算
- 基于 Agent 的模拟与仿真
- 基于 Agent 的数据挖掘
- 自适应与自组织理论
- Agent 与复杂网络分析
- 移动 Agent
- 基于 Agent 的智能信息系统
- Agent 技术应用、实践和经验
- 数据、信息融合的理论、方法与技术

##### 人工智能理论与技术

- 人工智能理论基础
- 知识科学与知识工程
- 智能机器人与机器人足球
- 机器感知与虚拟现实
- 智能控制与智能管理
- 图像和语音处理
- 生物信息学与人工生命
- 机器学习
- 数据挖掘
- 时空知识表示、推理与挖掘
- 社会网络分析及应用
- 神经网络与计算智能
- 人工免疫
- 粗糙集与软计算
- 自然语言处理与机器翻译
- 模式识别
- 人工智能应用

(下转第 156 页)